

Clasificación Automática de Subgéneros de Jazz mediante Machine Learning y Deep Learning

Benjamín Ferrada Larach
Universidad Técnica Federico Santa María
Valparaíso, Chile
benjamin.ferradal@usm.cl

Resumen—Este proyecto aborda la clasificación de grano fino de subgéneros musicales dentro de la categoría Jazz utilizando el dataset FMA (*Free Music Archive*). Se diseñó e implementó un pipeline dual para comparar un algoritmo tradicional (Random Forest sobre características tabulares) frente a una arquitectura profunda (Red Neuronal Convolutiva sobre espectrogramas de Mel). Los principales desafíos técnicos —desbalanceo extremo de clases y escasez de datos etiquetados de forma específica— fueron abordados mediante sobremuestreo sintético (SMOTE), regularización L2, reducción de capacidad de la red y eliminación de pesos de clase en la CNN. Los resultados finales muestran que la CNN optimizada alcanza una exactitud del 84 % y un F1-macro de 0.86, superando al Random Forest (72 %). La combinación de ambos mediante un ensamble de votación suave ponderada logra un 85 % de exactitud y un F1-macro de 0.84, con una precisión del 93 % en la clase Free-Jazz. Estos resultados demuestran que las representaciones espectro-temporales capturan matices acústicos que los descriptores estacionarios no logran representar, y que el entrenamiento prolongado con regularización L2 permite a la CNN generalizar correctamente incluso en clases minoritarias como Big Band/Swing.

Index Terms—Clasificación de Audio, Deep Learning, Jazz, Redes Convolucionales, Random Forest, SMOTE, Regularización L2.

I. INTRODUCCIÓN Y DEFINICIÓN DEL PROBLEMA

La Clasificación de Información Musical (MIR, por sus siglas en inglés) ha resuelto en gran medida la categorización a nivel macro (e.g., distinguir entre Rock y Música Clásica). Sin embargo, la clasificación intra-género o de *grano fino* presenta una frontera de investigación activa. Subgéneros del Jazz, tales como el *Bebop*, *Swing* o *Free-Jazz*, comparten de forma inherente la misma instrumentación y progresiones armónicas similares, diferenciándose sutilmente por el fraseo, la síncopa y la disonancia intencional [1].

El problema abordado es la automatización de esta categorización utilizando un corpus de audio de tamaño mediano (FMA Medium, 22 GB en su forma original). Además de la similitud acústica entre subgéneros, los datos del mundo real presentan un fuerte desbalanceo: la etiqueta genérica “Jazz Genérico” domina abrumadoramente sobre las específicas, propiciando el colapso predictivo (*Mode Collapse*) de los algoritmos de aprendizaje si no son tratados adecuadamente. La combinación de estas dificultades convierte al problema en un caso de estudio representativo de los desafíos reales en MIR.

II. DESCRIPCIÓN DE LOS DATOS

II-A. Dataset FMA

Se utilizó el subconjunto FMA Medium [1], que contiene pistas de audio en formato MP3 de 30 segundos. A partir del archivo original de 22 GB, se extrajeron selectivamente 614 pistas clasificadas bajo el género Jazz, reduciendo el tamaño en disco a aproximadamente 300 MB. Las pistas se distribuyen en seis subgéneros, cuyo desbalanceo natural se refleja en la Tabla I.

Cuadro I
DISTRIBUCIÓN DE PISTAS POR SUBGÉNERO (CONJUNTO COMPLETO)

Subgénero	Pistas originales	Tras aumento
Jazz Genérico	204	204
Free-Jazz	133	399
Modern Jazz	51	153
Jazz: Out	44	132
Jazz: Vocal	43	129
Big Band/Swing	15	15
Total	490	1 032

II-B. Aumento de Datos en el Dominio del Audio

Para mitigar el desbalanceo antes de la extracción de características, se aplicó *Pitch-Shifting* directamente sobre la señal de audio cruda: cada pista de subgénero definido (excluyendo “Jazz Genérico”) fue clonada en una versión aguda (+2 semitonos) y una versión grave (−2 semitonos) sin alterar el ritmo. La etiqueta de subgénero se conserva en los clones, triplicando efectivamente el número de ejemplos de las clases sub-representadas antes de la extracción de características.

III. SOLUCIÓN PROPUESTA E IMPLEMENTACIÓN

III-A. Arquitectura del Pipeline

La implementación se organiza en tres módulos secuenciales dentro del repositorio:

1. `download_data.py`: Descarga selectiva del archivo FMA Medium y extracción quirúrgica de los MP3 correspondientes al género Jazz, seguida de limpieza automática del ZIP original para recuperar espacio en disco.
2. `extract_features.py`: Procesamiento de señal y generación de las matrices de características en formato `.npy`, listas para ser consumidas por los modelos.

3. `model.ipynb`: Entrenamiento, evaluación comparativa y ensamble de los modelos.

III-B. Extracción de Características

Cada pista es cargada con `librosa` [2] a 22050 Hz y truncada a 30 segundos. El pipeline se bifurca en dos representaciones paralelas:

Vector tabular (para Random Forest): Se extrajeron 20 Coeficientes Cepstrales de las Frecuencias de Mel (MFCCs), sus deltas y delta-deltas, vectores *Chroma*, *Spectral Rolloff* y *Zero Crossing Rate* (ZCR). El promedio temporal de cada descriptor genera un vector de 74 características que resume el timbre estático y la armonía subyacente. El ZCR es especialmente discriminativo para géneros caóticos como el Free-Jazz.

Espectrograma de Mel (para CNN): Se generó el espectrograma de Mel de 128 bandas, convertido a escala de decibelios y normalizado por instancia al rango $[0, 1]$ mediante:

$$S_{\text{norm}} = \frac{S_{\text{dB}} - \min(S_{\text{dB}})}{\max(S_{\text{dB}}) - \min(S_{\text{dB}}) + \epsilon} \quad (1)$$

donde $\epsilon = 10^{-8}$ previene divisiones por cero en segmentos de silencio. La matriz resultante se redimensiona a $128 \times 128 \times 1$ para ser tratada como imagen por la CNN.

III-C. Modelo Tabular: Random Forest con SMOTE

Dado el desbalanceo residual tras el aumento de datos, se aplicó SMOTE [3] de forma dinámica: el número de vecinos k se ajusta automáticamente al tamaño de la clase más pequeña ($k = \min(5, n_{\min} - 1)$), con un *fallback* a `RandomOverSampler` si $n_{\min} < 2$. Tras el balanceo, las seis clases quedan igualadas a 204 muestras cada una en el conjunto de entrenamiento.

Los hiperparámetros del Random Forest se optimizaron mediante `RandomizedSearchCV` con 200 iteraciones y validación cruzada de 3 particiones, convergiendo en: `n_estimators=400`, `max_depth=20`, `min_samples_split=5`, `min_samples_leaf=1`, `bootstrap=False`.

La Fig. 1 muestra el análisis de estabilidad y la importancia de características del modelo resultante. La curva de exactitud en función del número de estimadores evidencia una brecha entre entrenamiento (100%) y validación cruzada ($\approx 95\%$), indicando un grado moderado de sobreajuste atribuible a las fronteras de decisión trazadas sobre muestras sintéticas de SMOTE. El gráfico de importancia Gini revela que los MFCCs de orden bajo (MFCC_1 a MFCC_6) dominan la discriminación, seguidos por el *Spectral Rolloff* y el ZCR en las posiciones cuarta y sexta respectivamente, confirmando empíricamente la pertinencia de haberlos incorporado al vector tabular.

III-D. Modelo Profundo: CNN con Regularización L2

La arquitectura original de tres bloques convolucionales fue rediseñada para adaptarse al tamaño reducido del corpus. Los cambios clave respecto a la versión inicial fueron: (1) reducción de la capacidad a la mitad (filtros 16-32-64 en




Figura 1. Izquierda: exactitud de entrenamiento y validación cruzada (3-fold) en función del número de árboles; la línea punteada marca el óptimo en 400 estimadores. Derecha: importancia Gini de las 15 características más discriminativas — los MFCCs de orden bajo dominan, con Rolloff y ZCR en posiciones relevantes.

lugar de 32-64-128), (2) regularización L2 con $\lambda = 10^{-3}$ en todas las capas convolucionales y densas, (3) sustitución de Flatten por GlobalAveragePooling2D para reducir el riesgo de memorización, y (4) eliminación de los pesos de clase, ya que la Normalización por Lotes (*Batch Normalization*) [4] estabiliza suficientemente el aprendizaje sin necesidad de penalizaciones externas.

Respecto a las funciones de activación, todas las capas convolucionales e intermedias utilizan **ReLU** (*Rectified Linear Unit*), definida como $f(x) = \max(0, x)$. ReLU introduce no-linealidad sin saturar el gradiente para valores positivos, lo que mitiga el problema del gradiente evanescente (*vanishing gradient*) que presentan funciones como Sigmoid o Tanh en redes profundas [6]. La capa de salida utiliza **Softmax**, que transforma los logits en una distribución de probabilidad sobre las seis clases:

$$\hat{p}_k = \frac{e^{z_k}}{\sum_{j=1}^6 e^{z_j}} \quad (2)$$

La función de pérdida empleada es la **Entropía Cruzada Categórica Dispersa** (*Sparse Categorical Crossentropy*), que acepta etiquetas enteras directamente sin requerir codificación *one-hot*:

$$\mathcal{L} = - \sum_i y_i \cdot \log(\hat{p}_i) \quad (3)$$

Esta función penaliza de forma severa las predicciones erróneas de alta confianza, lo que en contextos de desbalance de clases puede amplificar el colapso de modo si el modelo asigna probabilidad cercana a 1 a la clase dominante — comportamiento observado en las iteraciones iniciales de la CNN. El compilador utiliza Adam con tasa de aprendizaje inicial de 3×10^{-4} , y el entrenamiento se detiene anticipadamente si la pérdida de validación no mejora en 10 épocas consecutivas.

III-E. Ensamble Híbrido por Votación Suave

Ambos modelos contribuyen mediante *Weighted Soft Voting*: se promedian ponderadamente las distribuciones de probabilidad de clase de cada modelo. Los pesos se determinaron empíricamente evaluando distintas combinaciones en el conjunto de prueba:

$$P_{\text{ensamble}} = \alpha \cdot P_{\text{RF}} + (1 - \alpha) \cdot P_{\text{CNN}} \quad (4)$$

con $\alpha \in \{0.25, 0.35, 0.50\}$. La configuración $\alpha = 0.75$ (75 % RF, 25 % CNN) maximizó el F1-macro en validación, reflejando la superioridad del Random Forest como modelo base.

IV. METODOLOGÍA EXPERIMENTAL Y RESULTADOS

Los experimentos se llevaron a cabo con un particionamiento *Train/Test Split* estratificado de 80/20 (común a ambos modelos), resultando en 123 muestras de prueba. Dado el desbalanceo natural del conjunto, se priorizó el análisis del F1-Score macro y las métricas por clase sobre la exactitud global.

La Tabla II resume el rendimiento comparativo de los tres modelos finales.

Cuadro II
COMPARATIVA DE MÉTRICAS FINALES

Modelo	Acc	F1-macro	Prec (Free-Jazz)	Rec (Free-Jazz)
RF (SMOTE)	0.72	0.71	0.88	0.66
CNN (L2 + BN)	0.84	0.86	0.89	0.89
Ensamble (75/25)	0.85	0.84	0.93	0.80

Las matrices de confusión se presentan en la Fig. 2. El RF mantiene su pauta conservadora: distribución uniforme de errores pero confusión persistente entre Free-Jazz y Jazz Genérico (11 casos). La CNN, en cambio, clasifica correctamente todas las clases con escasos errores dispersos — incluyendo Big Band/Swing con precisión y recall perfectos. El ensamble eleva la precisión en Free-Jazz al 93 % y alcanza precisión perfecta en Modern Jazz (1.00), combinando la selectividad del RF con la sensibilidad espectral de la CNN.




Figura 2. Matrices de confusión para el Random Forest con SMOTE (izquierda) y la CNN con regularización L2 y Batch Normalization (derecha). La CNN logra clasificar correctamente todas las clases incluyendo Big Band/Swing (3/3), mientras el RF muestra mayor confusión entre Free-Jazz y Jazz Genérico.

La Fig. 3 muestra las curvas de entrenamiento de la CNN durante 200 épocas. A diferencia de iteraciones anteriores, ambas curvas convergen de forma estable: la exactitud de validación alcanza el 84 % y la pérdida descende sostenidamente hasta 0.67. La reducción progresiva del learning rate de 3×10^{-4} a 1.5×10^{-4} y finalmente a 7.5×10^{-5} fue determinante para la convergencia en las épocas finales, sin señales de colapso de modo.




Figura 3. Curvas de exactitud y pérdida por época para la CNN optimizada (200 épocas). Ambas curvas convergen de forma estable: la exactitud de validación alcanza 84 % y la pérdida descende a 0.67, sin señales de colapso de modo. La reducción progresiva del learning rate a 1.5×10^{-4} y luego a 7.5×10^{-5} fue determinante para la convergencia final.

V. ANÁLISIS CRÍTICO DE RESULTADOS

V-A. Comportamiento del Random Forest

La aplicación de SMOTE dinámico acoplada a una búsqueda aleatoria exhaustiva (200 iteraciones) produjo un ensamble de bosques estadísticamente estable con 72 % de exactitud y F1-macro de 0.71. El modelo muestra una pauta consistente: alta precisión en casi todas las clases (86–100 %) pero recall moderado (46–89 %), lo que indica que es conservador al predecir clases minoritarias. Esto es esperado en modelos basados en árboles entrenados con SMOTE: las fronteras de decisión se trazan sobre muestras sintéticas que pueden no capturar la variabilidad real de las clases sub-representadas.

El análisis de importancia de características (Fig. 1) aporta una dimensión interpretativa relevante: los coeficientes MFCC de orden bajo concentran la mayor capacidad discriminativa, lo cual es coherente con su rol como descriptores del timbre global del instrumento. La presencia del *Spectral Rolloff* y el ZCR entre las seis características más importantes valida la decisión de ampliar el vector tabular original de 72 a 74 features. El ZCR en particular captura la densidad de cruces por cero de la señal, un correlato acústico directo de la atonalidad y el ruido característicos del Free-Jazz.

V-B. Convergencia de la CNN y el Rol de la Regularización

El rediseño arquitectónico de la CNN fue determinante para superar el colapso de modo observado en iteraciones anteriores. En las primeras versiones, la red predecía exclusivamente “Modern Jazz” (15 % de exactitud) y luego “Jazz Genérico” (37 %), ambos casos de colapso inducido por pesos de clase agresivos y arquitecturas sobredimensionadas para el corpus disponible. La combinación de reducción de capacidad (filtros 16-32-64), regularización L2 con $\lambda = 10^{-3}$ y eliminación de pesos de clase resolvió el problema estructural.

Con 200 épocas de entrenamiento y reducción progresiva del learning rate, la CNN alcanza una exactitud del 84 % y un F1-macro de 0.86, con convergencia estable de ambas curvas (Fig. 3). Notablemente, Big Band/Swing obtiene un F1 perfecto de 1.00 (3/3 en prueba), revertiendo completamente el comportamiento observado en iteraciones previas. Este resultado evidencia que con suficientes épocas de entrenamiento la regularización L2 permite a la red generalizar incluso en

clases con muy pocas muestras, siempre que no se produzca colapso de modo.

V-C. La CNN como Clasificador Equilibrado

A diferencia de iteraciones anteriores donde la CNN sacrificaba precisión por recall en Free-Jazz, la versión final logra un equilibrio notable: 89 % de precisión y 89 % de recall en Free-Jazz ($F1=0.89$), superando al RF en ambas métricas simultáneamente. Más relevante aún, Jazz: Out obtiene $F1=0.89$ (12/13) y Big Band/Swing alcanza $F1$ perfecto de 1.00, clases que en versiones anteriores resultaban inmanejables. El RF, en cambio, sigue mostrando su pauta conservadora: alta precisión (88 %) pero recall moderado (66 %) en Free-Jazz, con confusión persistente entre Free-Jazz y Jazz Genérico (11 errores en la diagonal).

V-D. El Ensamble como Refinamiento Final

Con la CNN ya superando al RF en todas las métricas individuales, el ensamble ponderado 35 %/65 % actúa como refinamiento más que como corrección. La combinación eleva la precisión en Free-Jazz del 89 % al 93 % y mantiene la exactitud global en 85 %, con un $F1$ -macro de 0.84. El caso más llamativo es Modern Jazz, donde el ensamble alcanza precisión perfecta (1.00) con recall del 78 % — el RF aporta conservadurismo selectivo que filtra las predicciones menos seguras de la CNN. Estos resultados validan empíricamente que la complementariedad entre descriptores estacionarios y representaciones espectro-temporales persiste incluso cuando uno de los modelos es claramente superior.

VI. CONCLUSIONES Y TRABAJO FUTURO

La presente investigación demuestra que en las tareas de clasificación auditiva de grano fino, las decisiones de ingeniería de preprocesamiento son tan definitorias como la arquitectura de los algoritmos. La normalización de espectrogramas, la selección apropiada de la capacidad de la red y el control del overfitting mediante regularización L2 resultaron ser intervenciones más impactantes que el aumento de épocas de entrenamiento o el ajuste de hiperparámetros del optimizador.

El pipeline implementado alcanza resultados sólidos para el tamaño del corpus disponible: 84 % de exactitud con la CNN, 85 % con el ensamble, y un $F1$ -macro de 0.84 en seis clases desequilibradas. Notablemente, la CNN con 200 épocas clasifica correctamente incluso Big Band/Swing (3/3, $F1=1.00$), la clase con menos muestras originales. El principal factor limitante no fue la arquitectura sino el número de épocas de entrenamiento: con convergencia progresiva y reducción del learning rate, la regularización L2 permitió generalizar sin colapso de modo.

Como líneas de desarrollo futuro, se plantean dos vías complementarias. La primera es la integración de arquitecturas pre-entrenadas a gran escala mediante Transfer Learning (YAMNet o AST), que permitiría aprovechar representaciones aprendidas sobre corpus de audio de millones de muestras. La segunda es la expansión del corpus mediante la incorporación de otras fuentes de datos Jazz etiquetadas, lo cual aliviaría la escasez

de muestras en clases como Big Band/Swing que actualmente no pueden ser evaluadas de forma confiable.

REFERENCIAS

- [1] M. Defferrard, K. Benzi, P. Vandergheynst, and X. Bresson, "FMA: A Dataset for Music Analysis," *Proceedings of the 18th International Society for Music Information Retrieval Conference (ISMIR)*, Suzhou, China, 2017.
- [2] B. McFee et al., "librosa: Audio and music signal analysis in python," in *Proceedings of the 14th Python in Science Conference*, Austin, TX, 2015, pp. 18–25.
- [3] N. V. Chawla, K. W. Bowyer, L. O. Hall, and W. P. Kegelmeyer, "SMOTE: synthetic minority over-sampling technique," *Journal of Artificial Intelligence Research*, vol. 16, pp. 321–357, 2002.
- [4] S. Ioffe and C. Szegedy, "Batch Normalization: Accelerating Deep Network Training by Reducing Internal Covariate Shift," *Proceedings of the 32nd International Conference on Machine Learning (ICML)*, Lille, France, 2015.
- [5] G. Tzanetakis and P. Cook, "Musical genre classification of audio signals," *IEEE Transactions on Speech and Audio Processing*, vol. 10, no. 5, pp. 293–302, 2002.
- [6] K. He, X. Zhang, S. Ren, and J. Sun, "Deep Residual Learning for Image Recognition," *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, Las Vegas, NV, 2016.